UNIVERSIDAD
DE GRANADA

Facultad de Ciencias Económicas y Empresariales

Entrega Final

Econometría

Elena Rodero Jiménez
Carmen Rodríguez González
Carmen Sánchez Escobar

2025

Índice

Capítulos **Página**

1 Modelo e hipótesis planteadas **2**
1.1 Formulación del modelo de regresión lineal múltiple planteado. 2
1.2 Hipótesis iniciales previstas: ¿Qué variables se esperan significativas? ¿Cuáles deben ser los signos de los coeficientes estimados? 2

2 Datos **3**
2.1 Fuente exacta de la base de datos 3
2.2 Justificación de la relevancia temática y adecuación para análisis econométrico 3
2.2.1 Relevancia Temática 3
2.3 Resumen del preprocesamiento realizado a los datos: elección de variables, creación de dummies, rellenado de valores faltantes, eliminación de outliers, transformación de las variables, ... 3

3 Estimación del modelo lineal múltiple **5**
3.1 Estimación mediante Mínimos Cuadrados Ordinarios (OLS) 5
3.2 Evaluación inicial del ajuste mediante R2 y R2 ajustado 7
3.3 Significación individual de los regresores 7
3.4 Significación global del modelo 8

4 Verificación de las hipótesis clásicas **8**
4.1 Multicolinealidad: análisis VIF y Número de Condición. Medidas tomadas al respecto . 8
4.2 Normalidad de la perturbación aleatoria: test Kolmogorov-Smirnov 9
4.3 Heteroscedasticidad. Detección y estimación por MCP 11
4.4 Autocorrelación. Detección y estimación por Prais-Wistem 13

5 Predicción **16**
5.1 Predicción puntual para un caso específico de interés 16
5.2 Cálculo de intervalos de predicción y confianza 17

6 Conclusiones **20**
6.1 Valoración general del ajuste realizado 20
6.2 Comentarios sobre el cumplimiento de los supuestos 21
6.3 Utilidad predictiva del modelo y posibles mejoras 22

1. Modelo e hipótesis planteadas

1.1. Formulación del modelo de regresión lineal múltiple planteado.

Partiendo de nuestra primera base de datos, tenemos que las variables implicadas en el modelo son las siguientes:

- **Variable Dependiente (Y):** `exam_score` (Calificación obtenida en el examen).
- **Variables Explicativas (X):**
  - `hours_studied` (Horas estudiadas para el examen → Continua).
  - `sleep_hours` (Horas de sueño al día → Continua).
  - `attendance_percent` (Porcentaje de asistencia a clase → Continua).
  - `previous_scores` (Calificaciones obtenidas anteriormente → Continua).

```
== Tipos de datos ==
hours_studied         float64
sleep_hours           float64
attendance_percent    float64
previous_scores       float64
exam_score            float64
                       ...
student_id_S196         bool
student_id_S197         bool
student_id_S198         bool
student_id_S199         bool
student_id_S200         bool
Length: 204, dtype: object
```

Figura 1: Tipos de datos

El modelo planteado sería por tanto:

$$\text{exam_score} = \beta_0 + \beta_1 \cdot \text{hours_studied} + \beta_2 \cdot \text{sleep_hours} + \beta_3 \cdot \text{attendance_percent} + \beta_4 \cdot \text{previous_scores} + u$$

La base de datos también incluye la variable `student_id` (asigna un número de identificación único a cada dato → Binaria).

Posteriormente hablaremos más en profundidad de esta variable, adelantamos que, por su naturaleza categórica, no la tendremos en cuenta en el análisis de la base de datos.

1.2. Hipótesis iniciales previstas: ¿Qué variables se esperan significativas? ¿Cuáles deben ser los signos de los coeficientes estimados?

En principio podríamos esperar que todas las variables presentadas son significativas en el modelo, pues están relacionadas causalmente con la nota que un alumno obtiene en un examen.

Los signos de los coeficientes estimados esperados son positivos para todas las variables (un aumento en dicha variable debería ocasionar un aumento en la variable explicativa).

2. Datos

2.1. Fuente exacta de la base de datos

Los datos provienen de una base de datos de la página Kaggle:

`https://www.kaggle.com/datasets/saadaliyaseen/analyzing-student-academic-trends`

2.2. Justificación de la relevancia temática y adecuación para análisis econométrico

2.2.1. Relevancia Temática

La relevancia del tema radica en su impacto directo en la economía del capital humano y la política educativa.

- **Implicaciones Socioeconómicas:** Los resultados académicos (`exam_score`) son un predictor clave del éxito futuro (empleabilidad, nivel salarial, productividad). Analizar sus determinantes (`hours_studied`, `attendance_percent`, `previous_scores`, `sleep_hours`) permite identificar hábitos y factores modificables que pueden ser promovidos para mejorar el rendimiento.
- **Política Pública:** La comprensión de qué factores tienen el mayor impacto (según los coeficientes β) puede informar las decisiones de las instituciones educativas o gobiernos sobre la asignación de recursos. Por ejemplo, si la `attendance_percent` es muy significativa, se justifica invertir en políticas que fomenten la presencia en clase o aumentar la cuantía de las becas que permitan a los estudiantes dedicación exclusiva a su formación.

La base de datos es adecuada para un análisis econométrico utilizando el método de Mínimos Cuadrados Ordinarios (OLS) por las siguientes razones:

- **Modelo Lineal:** OLS requiere que la relación entre las variables sea lineal en los parámetros. Las variables disponibles (`hours_studied`, `sleep_hours`, etc.) son cuantitativas y, *a priori*, se puede asumir que su influencia sobre la `exam_score` se puede aproximar mediante una función lineal.
- **Tamaño Muestral:** La muestra consta de 200 observaciones. Este tamaño es suficiente para obtener estimaciones consistentes y eficientes por OLS, permitiendo la aplicación de los contrastes de hipótesis estándar (t y F).
- **Variabilidad:** La variable dependiente, `exam_score`, presenta una variabilidad adecuada (rango de 17.1 a 51.3 con una media de 34).
- **Naturaleza de las Variables:** Todas las variables explicativas son continuas, lo que facilita la interpretación directa de los coeficientes como cambios marginales sobre la nota final.

2.3. Resumen del preprocesamiento realizado a los datos: elección de variables, creación de dummies, rellenado de valores faltantes, eliminación de outliers, transformación de las variables, ...

	count	mean	std	min	25%	50%	75%	max
hours_studied	200.0	6.3255	3.227317	1.0	3.5	6.15	9.000	12.0
sleep_hours	200.0	6.6220	1.497138	4.0	5.3	6.70	8.025	9.0
attendance_percent	200.0	74.8300	14.249905	50.3	62.2	75.25	87.425	100.0
previous_scores	200.0	66.8000	15.663869	40.0	54.0	67.50	80.000	95.0
exam_score	200.0	33.9550	6.789548	17.1	29.5	34.05	38.750	51.3

Figura 2: Tipos de datos

Columna: student_id

student_id	count
S001	1
S002	1
S003	1
S004	1
S005	1
S006	1
S007	1
S008	1
S009	1
S010	1

Figura 3: Frecuencia de las 10 categorías más comunes por columna categórica

En un primer análisis de los datos vemos que no tenemos valores faltantes (en todas las variables tenemos 200 observaciones). En cuanto a la variable categórica, requiere poco análisis teniendo en cuenta que solo nos indica el id de cada estudiante.

La imagen inferior muestra el añadido de variables dummy para la representación de la variable `student_id`.

```
['student_id_S002',
 'student_id_S003',
 'student_id_S004',
 'student_id_S005',
 'student_id_S006',
 'student_id_S007',
 'student_id_S008',
 'student_id_S009',
 'student_id_S010',
 'student_id_S011',
 'student_id_S012',
 'student_id_S013',
 'student_id_S014',
 'student_id_S015',
 'student_id_S016',
 'student_id_S017',
 'student_id_S018',
 'student_id_S019',
 'student_id_S020',
 'student_id_S021']
```

Figura 4: Columnas añadidas(muestra) con get_dummies

Como hemos comentado antes, esta variable no aporta información útil en la interpretación del modelo, solo un identificador único para cada estudiante. Por tanto, aunque no eliminaremos las

columnas añadidas al modelo, no las usaremos. No se eliminaron valores atípicos ni tampoco tuvimos que realizar ningún tipo de transformación de variables.

3. Estimación del modelo lineal múltiple

3.1. Estimación mediante Mínimos Cuadrados Ordinarios (OLS)

Para determinar la relación lineal entre la variable dependiente y las explicativas, empleamos el método de Mínimos Cuadrados Ordinarios (OLS). Esta técnica es el estándar en econometría clásica debido a sus propiedades estadísticas óptimas (insesgadez y eficiencia) bajo los supuestos de Gauss-Markov.

El objetivo fundamental de OLS es encontrar la recta de regresión que mejor se ajuste a la nube de puntos observada. Para lograrlo, el algoritmo calcula los coeficientes que minimizan la Suma de los Errores al Cuadrado (SSE); es decir, busca reducir al mínimo posible la distancia vertical acumulada entre los datos reales y los valores predichos por el modelo.

```
                            OLS Regression Results
==============================================================================
Dep. Variable:             exam_score   R-squared:                       0.841
Model:                            OLS   Adj. R-squared:                  0.838
Method:                 Least Squares   F-statistic:                     258.7
Date:                Fri, 28 Nov 2025   Prob (F-statistic):           8.76e-77
Time:                        15:49:19   Log-Likelihood:                -482.21
No. Observations:                 200   AIC:                             974.4
Df Residuals:                     195   BIC:                             990.9
Df Model:                           4
Covariance Type:            nonrobust
=====================================================================================
                        coef    std err          t      P>|t|      [0.025      0.975]
-------------------------------------------------------------------------------------
const                -2.1421      1.671     -1.282      0.201      -5.437       1.153
hours_studied         1.5553      0.060     25.732      0.000       1.436       1.674
sleep_hours           0.9523      0.132      7.191      0.000       0.691       1.213
attendance_percent    0.1084      0.014      7.961      0.000       0.082       0.135
previous_scores       0.1773      0.013     13.995      0.000       0.152       0.202
==============================================================================
Omnibus:                       40.393   Durbin-Watson:                   2.034
Prob(Omnibus):                  0.000   Jarque-Bera (JB):                9.464
Skew:                          -0.129   Prob(JB):                      0.00881
Kurtosis:                       1.966   Cond. No.                         882.
==============================================================================
```

A continuación, presentamos una primera lectura de la tabla de resultados de la regresión OLS. Cabe señalar que cada uno de estos aspectos será analizado y validado en mayor profundidad en las secciones posteriores; el objetivo aquí es ofrecer una visión general de la calidad de la estimación y la significancia de las variables.

En la parte superior de la tabla observamos el R-squared (0.841) y el Adj. R-squared (0.838). A modo de pincelada, estos valores indican que el modelo tiene una capacidad explicativa muy alta, capturando más del 84 % de la varianza de las notas. No obstante, el análisis pormenorizado de si este ajuste es óptimo se comentará en el siguiente punto.

Más relevante en esta fase es la Prob (F-statistic), cuyo valor es 8.76e-77 (prácticamente cero). Esto confirma la validez global del modelo: rechazamos la hipótesis de que todas las variables explicativas sean nulas a la vez. El modelo, en su conjunto, funciona.

Por último, encontramos los criterios de información AIC (974.4) y BIC (990.9). La funcionalidad principal de estos indicadores es permitir la comparación entre diferentes modelos; buscan un equilibrio

entre la bondad de ajuste y la simplicidad (penalizan la inclusión de variables innecesarias). Cuanto más bajos sean estos valores en comparación con modelos alternativos, mejor será el modelo elegido.

La sección central desglosa el efecto de cada variable:

El análisis de los P-valores ($P > |t|$) muestra que todas las variables explicativas son altamente significativas (0.000), lo que confirma que ninguna de ellas ha sido incluida por azar; todas aportan información valiosa para predecir el rendimiento.

- **Horas de Estudio (`hours_studied`): El motor del rendimiento.**
  - Coeficiente: $\beta = 1{,}5553$.
  - Interpretación Económica: Es la variable con mayor impacto marginal. Por cada hora adicional dedicada al estudio, la nota final aumenta en promedio 1,55 puntos.
  - Precisión: Su error estándar es minúsculo (0.060), lo que indica una estimación extremadamente precisa.
  - Estadístico t (25.732): Es el valor más alto de toda la tabla. Esto nos dice que la señal de esta variable es 25 veces más fuerte que el ruido, convirtiéndola en el predictor más robusto del modelo.
- **Horas de Sueño (`sleep_hours`): El factor biológico.**
  - Coeficiente: $\beta = 0{,}9523$.
  - Interpretación: El descanso tiene un retorno casi unitario. Dormir una hora extra se traduce en casi 1 punto adicional en el examen (0,95).
  - Implicación: Esto valida cuantitativamente la importancia del descanso cognitivo; sacrificar horas de sueño para estudiar marginalmente más podría no ser eficiente si la fatiga reduce este coeficiente.
- **Historial Académico (`previous_scores`): La inercia.**
  - Coeficiente: $\beta = 0{,}1773$.
  - Interpretación: Por cada punto que el alumno tenga en su historial previo, su nota actual sube 0,17 puntos.
  - Lectura crítica: Aunque es significativa ($t = 13{,}99$), su impacto es mucho menor que el del esfuerzo actual. Un alumno brillante (notas previas altas) que no estudie, será superado rápidamente por un alumno promedio que dedique horas, ya que el retorno del estudio (1.55) es casi 9 veces mayor que el de la renta.ªcadémica (0.17).
- **Asistencia (`attendance_percent`): La constancia.**
  - Coeficiente: $\beta = 0{,}1084$.
  - Interpretación: Por cada 1 % adicional de asistencia, la nota mejora 0,10 puntos.
  - Escala: Aunque el coeficiente parece pequeño, debemos recordar la escala de la variable (0-100). Un incremento sustancial, como mejorar la asistencia un 10 %, reportaría 1 punto extra a la nota final.
- **La Constante (`const`) y su no-significancia**
  - Coeficiente: -2.1421.
  - Significancia: Con un P-valor de 0.201, no podemos rechazar la hipótesis nula de que la constante sea cero.
  - Interpretación: Estadísticamente, el intercepto no es distinto de cero. En términos prácticos, esto tiene sentido lógico: un alumno que estudie 0 horas, duerma 0 horas, tenga 0 asistencia y 0 notas previas, teóricamente tendría una nota cercana a cero (o negativa por el ajuste matemático), pero este escenario es imposible en la realidad. Que no sea significativa no

afecta a la calidad de las predicciones, simplemente indica que la recta de regresión pasa muy cerca del origen de coordenadas.

Las últimas dos columnas de la tabla ([0.025 y 0.975]) nos ofrecen el rango de valores probables para cada coeficiente poblacional. Analizar estos intervalos nos permite evaluar la precisión de nuestras estimaciones y validar visualmente su significancia.

La prueba del cero (Validación de significancia): Un coeficiente es estadísticamente significativo si su intervalo de confianza no incluye el cero. Observamos que los intervalos de `hours_studied` [1.436, 1.674], `sleep_hours` [0.691, 1.213], asistencia y `previous_scores` son todos estrictamente positivos. Al no cruzar el cero, confirmamos con un 95 % de seguridad que estas variables tienen un efecto positivo real.

Por el contrario, el intervalo de la constante (`const`) va de -5.437 a 1.153. Al cruzar por el cero (pasar de negativo a positivo), confirmamos que no podemos asegurar que el intercepto exista o sea distinto de nulo.

Precisión de la estimación (Ancho del intervalo): Destaca la variable `hours_studied`: Su intervalo es extremadamente estrecho (apenas 0.24 de diferencia entre el límite inferior y superior). Esto significa que el modelo es muy preciso determinando el impacto del estudio: sabemos que cada hora aporta entre 1.43 y 1.67 puntos, con muy poco margen de error. En comparación, `sleep_hours` tiene un intervalo algo más ancho proporcionalmente a su coeficiente (rango de 0.52 para un coeficiente de 0.95), lo que indica una estimación ligeramente más dispersa o variable entre la población.

En la parte inferior, la tabla nos ofrece las primeras pistas sobre si se cumplen los supuestos teóricos del modelo:

- **Normalidad (Omnibus y Jarque-Bera):** Las pruebas Omnibus y Jarque-Bera (JB) evalúan si los errores del modelo siguen una distribución normal. En nuestro caso, obtenemos p-valores muy bajos (Prob(Omnibus): 0.000 y Prob(JB): 0.008). Al ser ambos inferiores a 0.05, la conclusión preliminar es que rechazamos la hipótesis de normalidad; es decir, estadísticamente los errores no se distribuyen como una campana de Gauss perfecta. Esto es una .ªlerta"que deberemos investigar en profundidad más adelante para ver si afecta a la fiabilidad del modelo o si es aceptable dado el tamaño de la muestra.
- **Autocorrelación (Durbin-Watson):** Con un valor de 2.034, este test sugiere que no existe correlación entre los errores de distintos alumnos (independencia de las observaciones). Un valor cercano a 2 es el ideal teórico.
- **Multicolinealidad (Cond. No.):** El número de condición (882) evalúa si las variables explicativas están demasiado correlacionadas entre sí. Al ser un valor moderado (típicamente menor a 1000), sugiere preliminarmente que no hay problemas graves de multicolinealidad que inestabilicen el modelo.

3.2. Evaluación inicial del ajuste mediante R2 y R2 ajustado

A partir de los resultados obtenidos, podemos interpretar el comportamiento del modelo. Este presenta un R^2 de 0.841, lo que significa que explica el 84 % de la variación en las notas del examen, indicando que las variables seleccionadas capturan adecuadamente los factores que influyen en el resultado.

Es un valor muy alto para datos de ciencias sociales o educativas, lo que significa que el modelo es muy eficaz prediciendo el rendimiento. Solo queda un ∼16 % de variabilidad explicada por factores desconocidos (suerte, salud, problemas personales, etc.).

Dada la escasa diferencia entre ambos coeficientes podemos establecer que la penalización por variables poco significativas es mínima.

3.3. Significación individual de los regresores

El test de significación individual (t-test) consiste en comprobar si cada coeficiente de regresión (β_k) es significativamente distinto de cero. Si $\beta_k = 0$, la variable explicativa asociada no tiene un efecto

lineal sobre la variable dependiente (`exam_score`).

Formulación de las Hipótesis:

- Hipótesis Nula (H_0): $H_0 : \beta_k = 0$ (La variable no es significativa).
- Hipótesis Alternativa (H_1): $H_1 : \beta_k \neq 0$ (La variable es significativa).

Criterio de Decisión (Valor P):

- Si el Valor P es menor que $\alpha = 5\,\%$ (P-valor $< 0{,}05$), se rechaza H_0 y la variable es significativa.
- Si el Valor P es mayor o igual que α, no se rechaza H_0 y la variable no es significativa.

Conclusión para el Modelo: Como el Valor P es muy pequeño (próximo a 0) para cada variable, se rechaza H_0 en todos los casos. Por lo tanto, se puede afirmar que todas las variables (`hours_studied`, `sleep_hours`, `attendance_percent`, y `previous_scores`) son individualmente significativas en la explicación de la `exam_score` con una confianza del 95 %.

3.4. Significación global del modelo

El test de significación global F consiste en comprobar si todas las estimaciones son igual a 0, es decir, explica que ninguna de las variables explicativas (horas estudiadas, horas de sueño, porcentaje de asistencia, notas previas) tienen relación lineal con la nota del examen.

Si el estadístico F global fuera suficientemente mayor que 0 y su p valor muy pequeño, entonces se rechazaría H_0 y se puede afirmar que alguno de los coeficientes es distinto de 0, por lo que el modelo tiene capacidad explicativa.

Como se ha obtenido un estadístico F global igual a 258.6735638313304 y un p-valor 8.758592533735377e-77, se rechaza la hipótesis nula y podemos afirmar que al menos una de las variables contribuye de manera significativa a modelar la nota del examen con una confianza de $\alpha = 5$.

En resumen, el modelo presenta un ajuste globalmente significativo.

4. Verificación de las hipótesis clásicas

4.1. Multicolinealidad: análisis VIF y Número de Condición. Medidas tomadas al respecto

El problema de multicolinealidad consiste en la existencia de relaciones lineales entre dos o más variables independientes del modelo lineal uniecuacional múltiple.

	var	VIF
0	const	74.840675
1	hours_studied	1.014944
2	sleep_hours	1.048547
3	attendance_percent	1.004142
4	previous_scores	1.050271

Cuadro 1: Resultados del Factor de Inflación de la Varianza (VIF)

El factor de inflación de la varianza (VIF) detecta el grado de multicolinealidad. Mide cuánto se incrementa la varianza de un coeficiente de regresión debido a la colinealidad. No detecta multicolinealidad no esencial, es decir, aquella que sucede con la constante.

El criterio utilizado en este análisis es:

- $VIF > 10$: Indica una multicolinealidad grave.
- $VIF > 4$ ó 5: Se considera un problema moderado.
- VIF cercano a 1: Indica poca multicolinealidad para esa variable.

Observamos que todas las variables explicativas (`hours_studied`, `sleep_hours`, `attendance_percent`, `previous_scores`) tienen valores de VIF extremadamente bajos, cercanos a 1 (rango de 1.004 a 1.050). En consecuencia, determinamos que no existe un problema de multicolinealidad entre las variables explicativas del modelo. Estas variables son independientes entre sí.

Por otro lado, el VIF de la constante es muy elevado (74.84), lo que puede indicar que las variables explicativas están casi centradas en cero o tienen una magnitud muy diferente a la de la constante (que es una columna de unos). Tenemos, por tanto, un problema de colinealidad no esencial. La inestabilidad se limita al coeficiente de la constante y no afecta negativamente a los de las variables de interés. No se requiere ninguna medida, como podría ser eliminar una variable, debido a este VIF alto en la constante.

El Número de Condición es otra medida que evalúa la estabilidad numérica de la matriz de datos. Tiene en cuenta la relación de las variables exógenas con la constante, es decir, detecta multicolinealidad no esencial.

El criterio utilizado es:

- $\sqrt{k} < 10$: Baja colinealidad.
- $10 \leq \sqrt{k} \leq 30$: Colinealidad moderada a fuerte.
- $\sqrt{k} > 30$: Colinealidad grave.

Tenemos que el número de condición es muy alto (882.2724502346254). Esto es debido a la constante. Cabe destacar que las unidades de las medidas, por ejemplo, las horas de sueño (`sleep_hours`) se mueven en el rango [4.0, 9.0], mientras que otras variables como el porcentaje de asistencia (`attendance_percent`), se mueve en un rango mucho más amplio [50.3, 100.0]. Esto puede causar que en el modelo parezca que la variable `sleep_hours` es casi constante.

4.2. Normalidad de la perturbación aleatoria: test Kolmogorov-Smirnov

El supuesto de normalidad de la perturbación aleatoria establece que el término de la perturbación aleatoria, u_i, se distribuye como una variable aleatoria normal con media cero y varianza constante. Esto es necesario para los estadísticos t y F, y para que los intervalos de confianza para los coeficientes estimados sean precisos.

$u \sim \mathcal{N}(0, \sigma^2 I_n)$

Como primera aproximación al estudio de la normalidad, se presenta el **histograma de frecuencias de los residuos estimados** (Figura 5). En el eje de abscisas se representan los valores de los residuos u_i, es decir, la diferencia entre el valor observado y el estimado por el modelo. El eje de ordenadas muestra la frecuencia relativa o densidad de probabilidad de dichos valores.

Ofrece una visión general de la simetría y la forma de la distribución. Una distribución normal ideal es simétrica y tiene forma de çampanaçentrada en cero. La distribución no presenta la forma de campana perfecta. Las barras no tienen el pico central y caída suave; las frecuencias de las barras alrededor de -1, 1 y 3 son relativamente similares, dándole una apariencia más uniforme. El histograma no es concluyente por sí mismo. Visualmente, no es una campana perfecta, por lo que podríamos pensar que las colas pueden no ser perfectamente normales.

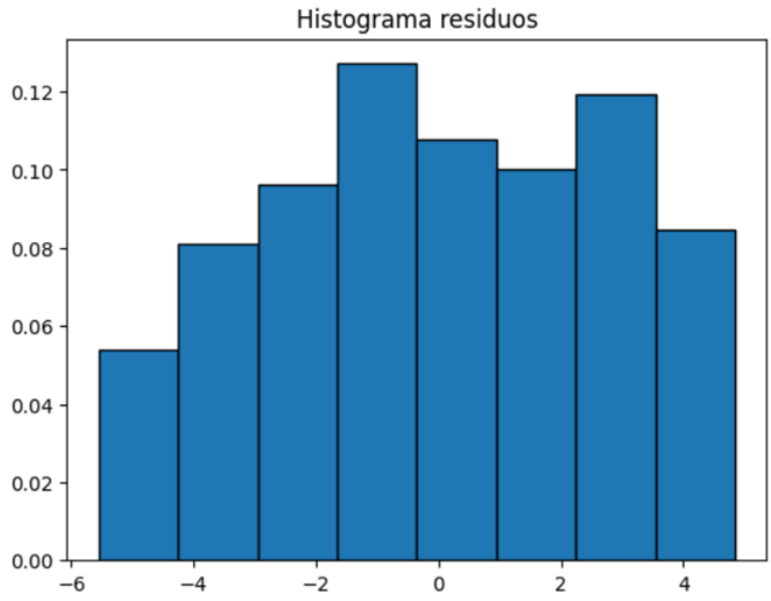

Figura 5: Normalidad de la perturbación aleatoria: test Kolmogorov Smirnov.

Otra herramienta para comprobar la normalidad de la perturbación aleatoria es el **gráfico Q-Q** (Figura 6), que confronta la distribución empírica de los residuos con una distribución normal teórica. En el eje de abscisas se sitúan los cuantiles teóricos, mientras que en el de ordenadas, los cuantiles muestrales (los valores reales ordenados de los residuos observados). La línea roja diagonal representa la referencia de normalidad perfecta.

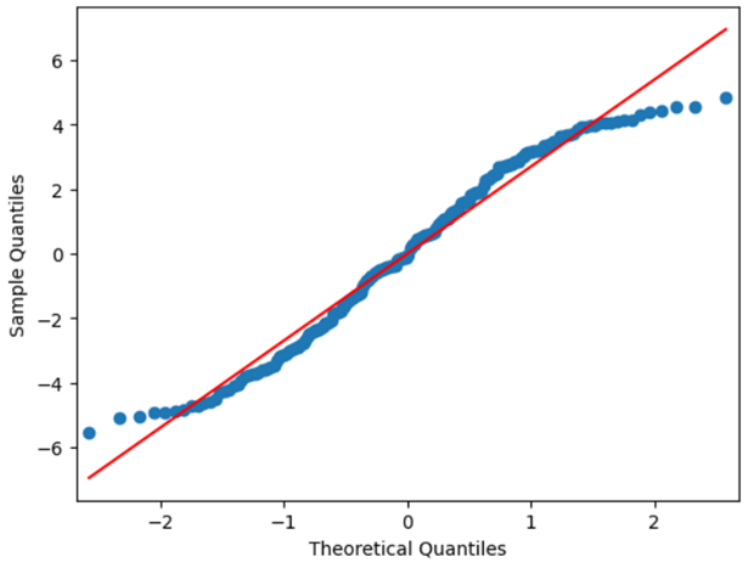

Figura 6: Gráfico Q-Q

Para que los residuos sean normales, los puntos deben caer lo más cerca posible de la línea roja. Observando la gráfica, en la zona central (cerca de 0), los puntos se alinean muy bien con la línea roja. En los extremos o colas (aproximadamente por debajo de -1.5 y por encima de 1.5 en el eje X), los puntos se desvían ligeramente de la línea. En la cola izquierda (inferior), los puntos están por encima de la línea, sugiriendo una cola izquierda con más observaciones muy negativas de lo que predice la normal. En la cola derecha (superior), los puntos se curvan ligeramente por debajo de la

línea, sugiriendo un posible sesgo positivo en los valores más extremos.

En conclusión, aunque hay algunas desviaciones en las colas la fuerte alineación central indica una distribución que es aproximadamente normal.

Por último, utilizaremos el **test de Kolmogorov-Smirnov** para confirmar analíticamente lo observado en los gráficos. Se trata de una prueba no paramétrica que determina la bondad de ajuste comparando la función de distribución acumulada empírica de nuestros residuos estandarizados con la función de distribución acumulada teórica de una normal estándar.

Las hipótesis del contraste son:

- H_0: Los residuos siguen una distribución Normal.
- H_1: Los residuos NO siguen una distribución Normal.

Los resultados obtenidos de esta prueba son un estadístico de prueba D igual a 0.0685 y un P-valor igual a 0.2911.

- Se rechaza H_0 si el p-valor es menor que el nivel de significación ($\alpha = 0{,}05$).
- No se rechaza H_0 si el p-valor es mayor o igual que α.

En este caso, dado que el p-valor (0,2911) es mayor que α (0,05), no existe evidencia suficiente para rechazar la hipótesis nula.

En conclusión, a un nivel de confianza del 95 %, podemos afirmar que los residuos del modelo se comportan siguiendo una distribución normal. Esto valida las inferencias estadísticas (pruebas t y F) realizadas en el modelo.

4.3. Heteroscedasticidad. Detección y estimación por MCP

Se dice que un modelo de regresión presenta heteroscedasticidad cuando la varianza del término de perturbación no permanece constante a lo largo del tiempo.

Un supuesto fundamental del modelo es la homocedasticidad. Este supuesto establece que la varianza de las perturbaciones aleatorias es constante para todas las observaciones, independientemente de los valores que tomen las variables explicativas:

$$Var(u_i|X) = \sigma^2 = \text{cte}$$

El incumplimiento de este supuesto (heterocedasticidad) no sesga los estimadores de los coeficientes, pero sí afecta a su eficiencia y, lo que es más crítico, invalida los estimadores de la varianza. Esto provocaría que los contrastes de significación (t y F) y los intervalos de confianza fueran erróneos.

En primer lugar, utilizamos métodos gráficos.

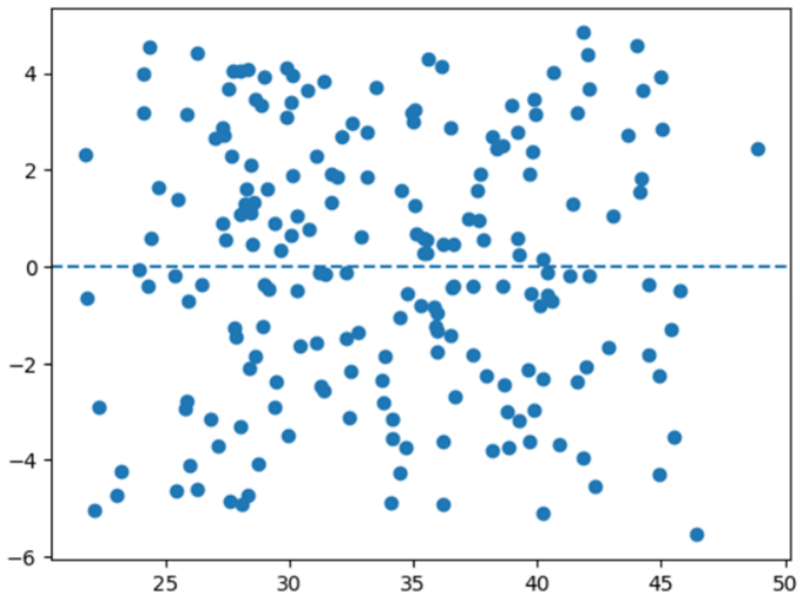

Figura 7: Gráfico de dispersión de residuos

Se observa un gráfico de dispersión que relaciona la predicción que hace el modelo para la variable dependiente y_i estimada (eje abscisas) con los residuos estimados e_i. Bajo el supuesto de homocedasticidad, esperaríamos observar una nube de puntos aleatoria y dispersa alrededor de la línea cero, sin ningún patrón claro. De lo contrario, estaríamos ante un caso de heterocedasticidad del modelo.

Se observa que la dispersión vertical de los residuos alrededor del cero se mantiene en todo el rango de valores [20, 50]. Por lo tanto, sugiere que el modelo cumple con el supuesto de homocedasticidad.

En el siguiente gráfico analizamos el comportamiento de los residuos respecto a variable explicativa `exam_score` con el objetivo de descartar una posible heterocedasticidad vinculada a la variable. El diagrama de dispersión relaciona los valores observados de la variable independiente `exam_score` (eje abscisas) con los residuos estimados e_i.

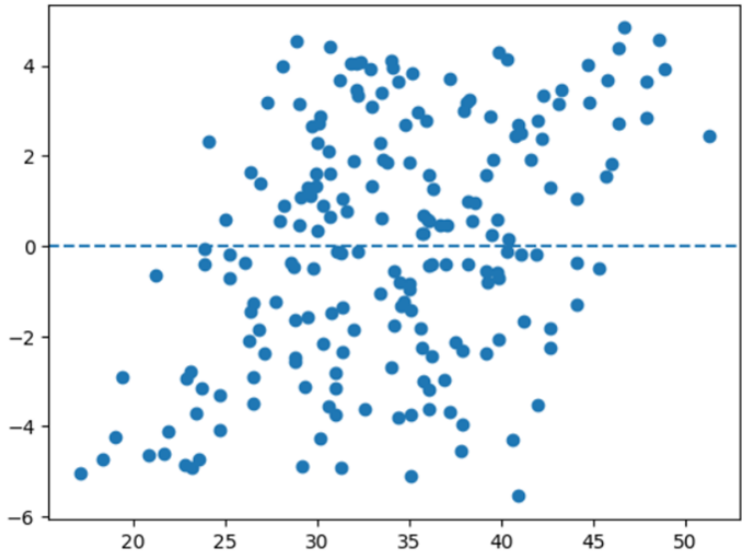

Figura 8: Comportamiento de los residuos respecto a la variable

Como se ha hecho anteriormente, notamos que los puntos se distribuyen de manera aleatoria alrededor de la banda del cero sin mostrar patrones ni tendencias. Tampoco se observa un aumento progresivo de la dispersión a medida que aumenta la nota. Entonces, concluimos que no existe un problema de heterocedasticidad causado por esta variable.

A continuación, usamos métodos analíticos para confirmar que los resultados obtenidos gráficamente son correctos. Todos los tests plantean las siguientes hipótesis:

- H_0: Homocedasticidad (Varianza constante de los errores).
- H_1: Heterocedasticidad (La varianza de los errores no es constante).

El nivel de significancia seleccionado es $\alpha = 0{,}05$.

En primer lugar, el **Test de Goldfeld-Quandt** divide la muestra en dos subgrupos para comparar sus varianzas. El P-valor de 0.4818, al ser superior al nivel de significancia, sugiere que no se encuentra evidencia suficiente para rechazar la hipótesis nula de varianza constante.

Posteriormente, el **Test de Breusch-Pagan**, que analiza si la varianza de los residuos depende de las variables explicativas del modelo a través de una forma lineal. El P-valor de 0.9236 conlleva que , al igual que en la prueba anterior, este resultado refuerza la ausencia de heterocedasticidad.

El **Test de White** considera posibles interacciones entre las variables. Con un P-valor de 0.2055, confirma nuevamente que no existe evidencia estadística para rechazar la hipótesis nula.

El **Test de Glejser** tiene como objetivo investigar si la varianza de los residuos presenta una relación funcional específica con las variables explicativas `hours_studied` y `sleep_hours`.

Para ello, se toman dichas variables elevadas a distintas potencias h.

```
Variable hours_studied:
    p-valor hours_studied^-3: 0.99387... R^2: 2.987e-07
    p-valor hours_studied^-2: 0.81041... R^2: 0.00029
    p-valor hours_studied^-1: 0.54781... R^2: 0.00182
    p-valor hours_studied^1:  0.40939... R^2: 0.00343
    p-valor hours_studied^2:  0.56294... R^2: 0.00169
    p-valor hours_studied^3:  0.76434... R^2: 0.00045
Variable sleep_hours:
    p-valor sleep_hours^-3:   0.63401... R^2: 0.00114
    p-valor sleep_hours^-2:   0.63841... R^2: 0.00111
    p-valor sleep_hours^-1:   0.64578... R^2: 0.00106
    p-valor sleep_hours^1:    0.66428... R^2: 0.00095
    p-valor sleep_hours^2:    0.67247... R^2: 0.00090
    p-valor sleep_hours^3:    0.67847... R^2: 0.00086
```

Como todos los p-valores superan alpha, concluimos que la varianza del error no depende de la magnitud de las variables independientes.

Dado los resultados gráficos y analíticos, concluimos que el modelo cumple el supuesto de homocedasticidad y que los estimadores de Mínimos Cuadrados Ordinarios son eficientes.

La estimación por Mínimos Cuadrados Ponderados (MCP) es el método correctivo habitual ante la presencia de heterocedasticidad. Su objetivo es transformar el modelo original dividiendo las variables por una estimación de la desviación típica del error, recuperando así la eficiencia de los estimadores. Sin embargo, como no existe problema de heterocedasticidad, aplicarlo en este modelo es innecesario.

4.4. Autocorrelación. Detección y estimación por Prais-Wistem

El supuesto de incorrelación establece que las perturbaciones aleatorias correspondientes a diferentes observaciones son independientes entre sí, es decir, no existe covarianza entre ellas:

$$Cov(u_i, u_j) = E[(u_i - E[u_i])(u_j - E[u_j])] = 0 \quad \text{para } i \neq j$$

En primer lugar, analizamos el caso de autocorrelación con métodos gráficos.

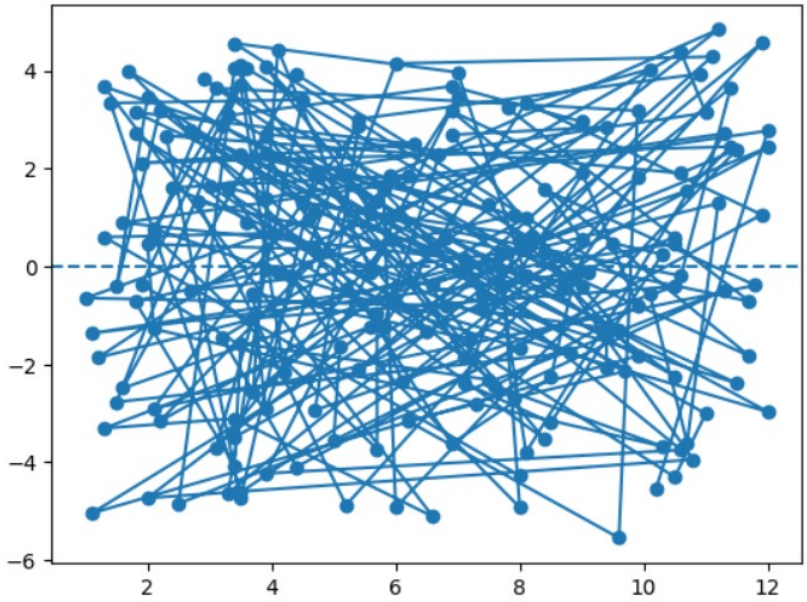

Figura 9: Evolución de los residuos

Este gráfico muestra la evolución de los residuos. Bajo el supuesto de no autocorrelación se esperaría no encontrar ciclos ni tendencias. De lo contrario, estaríamos ante un problema de autocorrelación. Como observamos, los residuos oscilan aleatoriamente, lo que sugiere que el residuo en un momento t no depende de los anteriores.

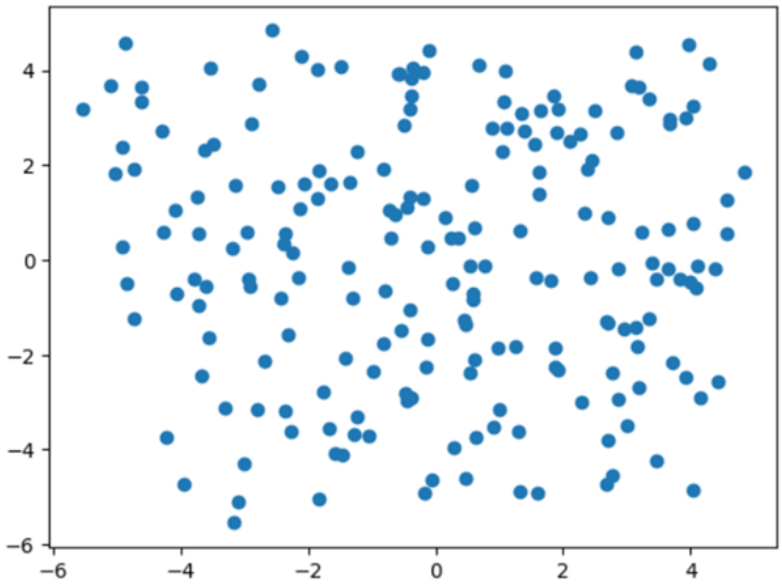

Figura 10: Gráfico de dispersión con retardos

Este segundo gráfico es de dispersión con retardos. El objetivo es descartar una relación entre el error de un momento t con el del periodo anterior e_{t-1}. Relaciona el residuo en el eje de abscisas con su propio valor retardado en el eje de ordenadas. Al igual que antes, si los puntos se distribuyeran aleatoriamente no existiría problema de autocorrelación. Sin embargo, una pendiente ascendente sugiere

autocorrelación positiva y una pendiente negativa sugiere autocorrelación negativa. Como no estamos ante tal caso, concluimos que no existe este problema.

Como métodos analíticos se ha escogido el Test de Ljung-Box y el contraste Durbin Watson. Los tests plantean las siguientes hipótesis:

- H_0: No Autocorrelación (Independencia de los errores).
- H_1: Autocorrelación (Existe correlación).

El nivel de significancia seleccionado es $\alpha = 0{,}05$.

El **test de Ljung-Box** contrasta la hipótesis nula de que las primeras m autocorrelaciones, ρ_m, son cero.

$$\begin{cases} H_0 : \rho_1 = \rho_2 = \cdots = \rho_m = 0 \\ H_1 : \exists i \in \{1, 2, \ldots, m\} \text{ tal que } \rho_i \neq 0 \end{cases}$$

En todos los casos analizados, los p-valores son muy superiores a 0,05, por lo que no existe evidencia estadística para rechazar la hipótesis nula de independencia.

El **contraste de Durbin-Watson** resulta adecuado si suponemos que la autocorrelación que presenta el término de perturbación pudiera ser descrito mediante un proceso autorregresivo de orden uno: $u_t = \rho u_{t-1} + \varepsilon_t$ donde ε_t es ruido blanco.

Gráficamente se tiene:

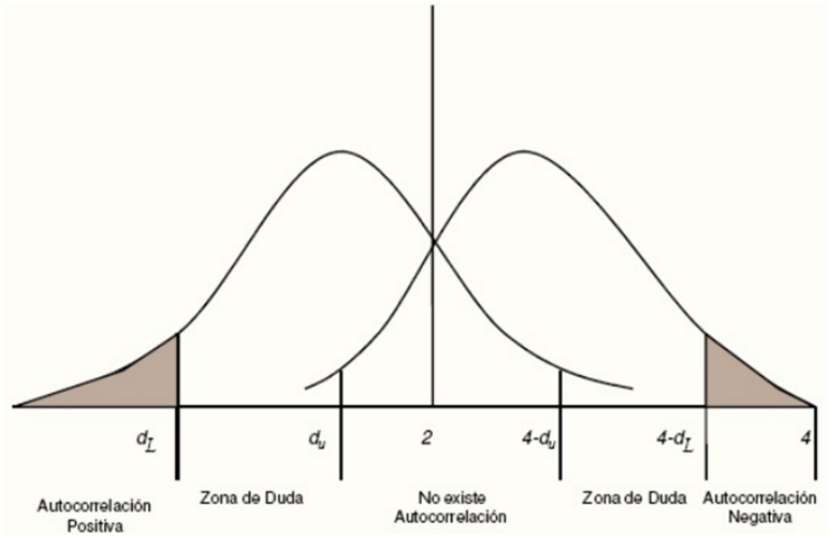

Figura 11: Durbin-Watson

Como el valor obtenido se encuentra cercano a 2, y tal como describe la tabla, se acepta la ausencia de autocorrelación. En conclusión, como indican los métodos gráficos y analíticos, el modelo no presenta autocorrelación y que los estimadores de Mínimos Cuadrados Ordinarios son eficientes y las inferencias válidas.

El **método de Prais-Winsten** es un procedimiento iterativo diseñado para corregir la presencia de autocorrelación de primer orden en los términos de error de un modelo de regresión lineal.

En primer lugar, se observa la salida del proceso iterativo. El algoritmo ha necesitado 9 iteraciones para converger. El parámetro de autocorrelación estimado (Rho) es de -0.03601301. Este valor, extremadamente cercano a cero, indica que la correlación detectada por el algoritmo es prácticamente nula, lo cual concuerda con la ausencia de autocorrelación obtenida anteriormente.

El estadístico Durbin-Watson del modelo transformado es de 1.991. Al estar casi perfectamente en el valor de 2, confirma que el modelo final ha eliminado cualquier rastro de autocorrelación de primer orden en los residuos.

Respecto a la significación de las variables, observamos que los coeficientes estimados para `hours_studied`, `sleep_hours`, `attendance_percent` y `previous_scores` mantienen p-valores de 0.000. Esto indica que todas las variables explicativas siguen siendo estadísticamente significativas al nivel $\alpha = 0{,}05$ después de la corrección.

El R-cuadrado ajustado se mantiene alto en 0,839. Dado que el ρ estimado es casi nulo y los resultados apenas difieren de una estimación MCO estándar, concluimos que el modelo original no sufría un problema real de autocorrelación. La aplicación del método de Prais-Winsten confirma que la corrección aplicada ha sido mínima y que los resultados obtenidos por MCO eran ya fiables.

```
Iteraciones = 9 Converge: True
Rho =   [-0.03601301]
                            GLSAR Regression Results
==============================================================================
Dep. Variable:             exam_score   R-squared:                       0.842
Model:                          GLSAR   Adj. R-squared:                  0.839
Method:                 Least Squares   F-statistic:                     259.4
Date:                Mon, 01 Dec 2025   Prob (F-statistic):           1.16e-76
Time:                        09:11:07   Log-Likelihood:                -478.89
No. Observations:                 199   AIC:                             967.8
Df Residuals:                     194   BIC:                             984.2
Df Model:                           4
Covariance Type:            nonrobust
==========================================================================================
                         coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                 -2.1339      1.668     -1.280      0.202      -5.423       1.155
hours_studied          1.5573      0.060     25.918      0.000       1.439       1.676
sleep_hours            0.9731      0.132      7.352      0.000       0.712       1.234
attendance_percent     0.1092      0.014      8.074      0.000       0.083       0.136
previous_scores        0.1743      0.013     13.795      0.000       0.149       0.199
==============================================================================
Omnibus:                       36.373   Durbin-Watson:                   1.991
Prob(Omnibus):                  0.000   Jarque-Bera (JB):                9.132
Skew:                          -0.139   Prob(JB):                       0.0104
Kurtosis:                       1.988   Cond. No.                         914.
==============================================================================
```

Figura 12: Prais-Winsten

5. Predicción

5.1. Predicción puntual para un caso específico de interés

La predicción puntual constituye el primer nivel de inferencia en un modelo de regresión lineal. Consiste en estimar un único valor específico (y) para la variable dependiente, dado un conjunto concreto de valores para las variables explicativas. Este valor no es aleatorio, sino que es el resultado de la combinación lineal de los coeficientes estimados por Mínimos Cuadrados Ordinarios (OLS) y los datos observados.

Estadísticamente, la predicción puntual representa el **valor esperado condicional**; es decir, es la mejor estimación del promedio de la variable objetivo para un individuo que cumpla con esas características específicas, minimizando el error cuadrático medio.

Una vez ajustado el modelo que relaciona el rendimiento académico con variables como las horas de estudio o el sueño, el siguiente paso es utilizarlo para realizar pronósticos. Al sustituir los valores de un caso específico en nuestra ecuación de regresión estimada, obtenemos un único valor numérico. Este dato actúa como nuestro 'mejor pronóstico' individual, basándose en los patrones históricos aprendidos por el modelo.

Para calcular estas predicciones concretas se han utilizado los datos de las tres primeras observaciones del conjunto de datos original (`datos_limpios.csv`).

Index	hours_studied	sleep_hours	attendance_percent	previous_scores	exam_score
0	8.0	8.8	72.1	45	30.2
1	1.3	8.6	60.7	55	25.0
2	4.0	8.2	73.7	86	35.8

Cuadro 2: Datos de las tres primeras observaciones

Predicciones y bandas (95 %):

Index	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_upper
0	34.473	0.418	33.648	35.297	29.023	39.922
1	24.399	0.501	23.411	25.387	18.923	29.876
2	35.122	0.439	34.256	35.988	29.666	40.578

Cuadro 3: Resultados de la predicción puntual e intervalos

La columna `mean` es la predicción puntual, el valor exacto que predice la fórmula. Es la estimación del Valor Esperado Condicional ($E[Y|X]$). Matemáticamente, es el resultado de sustituir los valores de las variables explicativas en la ecuación de la recta que ha ajustado el modelo. Asume que el término de error es cero. En nuestro caso concreto, es la nota que el modelo calcula que debería sacar ese alumno basándose solo en sus horas de estudio, sueño, etc.

Para el primer estudiante analizado (índice 0):

- **La Predicción Puntual (mean): 34,473.** Es el dato central. Según las horas que ha estudiado, dormido y su asistencia, el modelo calcula matemáticamente que su nota exacta debería ser un 34,47. Es nuestro mejor número único si no podemos dar rangos.

Al observar las filas 1 y 2, vemos que se repite un patrón muy consistente.

Para un nuevo dato, no perteneciente al modelo, con los siguientes valores: `const`: [1.0], `hours_sleep`: [9], `previous_scores`: [80], `attendance_percent`: [60], `hours_studied`: [5].

Predicción para un nuevo punto (95 %):

	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_upper
0	34.891	0.497	33.911	35.870	29.416	40.366

Cuadro 4: Predicción para el nuevo dato

El modelo estima una nota de 34,89. Este resultado es revelador. A pesar de que el perfil del alumno incluye buenas características (duerme 9 horas y tiene un historial de notas de 80), el hecho de estudiar solo 5 horas penaliza drásticamente el resultado. Esto confirma que, en este modelo de regresión, la variable `hours_studied` es el factor dominante para aprobar.

5.2. Cálculo de intervalos de predicción y confianza

Aunque la predicción puntual nos ofrece un valor estimado concreto, por sí sola es insuficiente para la toma de decisiones rigurosa, ya que no nos informa sobre el grado de certeza de dicho resultado. En cualquier modelo econométrico, es extremadamente improbable que el valor real futuro coincida exactamente con la estimación puntual. Por ello, es necesario complementar esa cifra con medidas que cuantifiquen la incertidumbre.

Para abordar esta variabilidad, calculamos dos tipos de rangos probabilísticos que, aunque relacionados, responden a preguntas muy diferentes:

- **Intervalos de Confianza (IC):** Se centran en estimar el valor esperado o promedio. Nos indican, con un nivel de confianza del 95 %, dónde se sitúa la verdadera media poblacional para un perfil determinado, considerando únicamente la varianza de los estimadores del modelo.

- **Intervalos de Predicción (IP):** Se centran en una observación individual. Son rangos necesariamente más amplios, ya que deben capturar no solo la incertidumbre del modelo (como hace el IC), sino también la variabilidad aleatoria e inherente a cada individuo (el término de error).

A continuación, analizamos estos intervalos para nuestros casos de estudio, lo que nos permitirá distinguir entre la tendencia general del modelo y el riesgo asociado a un estudiante concreto. Siguiendo con las tablas de datos del ejemplo anterior:

- `mean_se` es el error estándar de la media, cuantifica la precisión con la que el modelo estima el valor promedio; un valor bajo indica que la predicción se realiza en una zona donde el modelo tiene muchos datos y es robusto, mientras que un valor alto alerta de que estamos intentando predecir en una zona desconocida o extrapolada (extremo de la muestra).
- Las columnas `mean_ci_lower` y `mean_ci_upper` miden la incertidumbre sobre la estimación de la media poblacional. Refleja la precisión de tu modelo. Si se tomasen otras muestras de alumnos infinitas veces y se calculara la recta de regresión cada vez, el 95 % de esas rectas pasarían por este intervalo. Solo tiene en cuenta el error de muestreo de los coeficientes (β). Nos indican dónde estaría la nota media de un grupo infinito de alumnos con esas mismas características.
- Finalmente, las columnas `obs_ci_lower` y `obs_ci_upper` miden la incertidumbre sobre una nueva observación individual, a la incertidumbre del modelo usada anteriormente sumamos la inherente al individuo. Si un alumno saca una nota que está fuera de este intervalo (por ejemplo, saca un 20 y el `obs_ci_lower` era 40), es una .ªlerta roja". Ese caso es estadísticamente anómalo y merece ser estudiado por separado.

Para el primer estudiante analizado (índice 0), según el nivel de precisión que necesitemos atenderemos a una u otra predicción:

- **El Intervalo de Confianza (`mean_ci`): [33,648 — 35,297].** Aquí hablamos del promedio del grupo. El modelo nos dice con un 95 % de seguridad que, si tuviéramos infinitos estudiantes con estas mismas características exactas, la nota media de todos ellos estaría confinada en este rango muy estrecho. Fíjate que el margen es de apenas 1,6 puntos; esto indica que el modelo tiene muy claro dónde está el promedio.
- **El Intervalo de Predicción (`obs_ci`): [29,023 — 39,922].** Aquí hablamos de la realidad individual. Como este estudiante concreto puede tener un mal día, dolor de cabeza o suerte, el rango se abre mucho más (casi 11 puntos de diferencia). Aunque esperamos un 34,47, no nos sorprendería estadísticamente que sacara un 29 o un 40. Cualquier nota dentro de ese margen es "normal"para su perfil.

El gráfico superior compara visualmente las dos magnitudes de error para el estudiante analizado.

- La barra azul representa el **Intervalo de Confianza (IC)**. Al ser muy corta, confirma visualmente que la estimación del promedio es muy precisa. El modelo tiene muy clara la tendencia central.
- La barra naranja representa el **Intervalo de Predicción (IP)**. Su longitud, mucho mayor que la azul, ilustra el ruido.º variabilidad que aporta el individuo. La enorme diferencia de tamaño entre ambas barras nos recuerda que, aunque conozcamos bien la teoría (barra azul), predecir la realidad individual (barra naranja) siempre conlleva un margen de error significativamente mayor.

Al observar las filas 1 y 2, vemos que se repite un patrón muy consistente que valida la calidad de tu modelo:

En los tres casos, la distancia entre el límite inferior y superior del intervalo de predicción (`obs_ci`) es casi idéntica (aproximadamente 10,9 puntos de amplitud).

- Fila 0: $39,9 - 29,0 \approx 10,9$
- Fila 1: $29,8 - 18,9 \approx 10,9$
- Fila 2: $40,5 - 29,6 \approx 10,9$

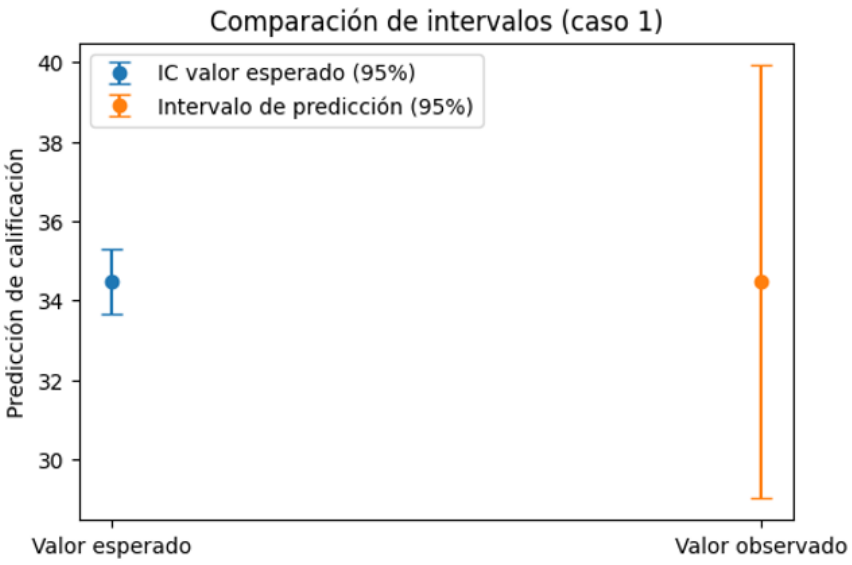

Figura 13: Comparación de intercalos (caso 1)

Esto es muy buena señal (técnicamente sugiere **homocedasticidad**), ya que significa que el modelo es igual de fiable prediciendo notas bajas (fila 1, predicción de 24,4) que notas medias (filas 0 y 2, predicción de ∼34-35). No pierde precisión según el tipo de alumno.

En todos los casos, el intervalo de confianza (`mean_ci`) es muy estrecho. Esto confirma que el modelo ha captado muy bien la tendencia general de los datos, aunque, como es lógico, siempre debamos dejar un margen más amplio (el `obs_ci`) para predecir la nota de un alumno individual por los factores aleatorios que no podemos controlar.

Como en el apartado anterior, para un nuevo dato, no perteneciente al modelo, con los siguientes valores: `const`: [1.0], `hours_sleep`: [9], `previous_scores`: [80], `attendance_percent`: [60], `hours_studied`: [5].

Predicción para un nuevo punto (95 %):

	mean	**mean_se**	**mean_ci_lower**	**mean_ci_upper**	**obs_ci_lower**	**obs_ci_upper**
0	34.891	0.497	33.911	35.870	29.416	40.366

El Error Estándar de la Media es de 0,497. Este valor es extremadamente bajo y, lo más importante, es prácticamente idéntico al error estándar que vimos en las tres primeras observaciones (que oscilaba entre 0,41 y 0,50). Al obtener un error tan parecido al de los datos de entrenamiento, confirmamos que este nuevo perfil (5h estudio, 9h sueño) es un caso ”típico.º familiar para el modelo. No estamos extrapolando ni introduciendo valores extraños; el modelo se siente igual de seguro prediciendo para este nuevo alumno que para los que ya conocía.

El intervalo para este individuo concreto abarca desde 29,4 hasta 40,4. Este rango es crucial. Nos dice con un 95 % de confianza que, incluso en el escenario más optimista contemplado por el modelo (límite superior de 40,37), este alumno no alcanzaría el aprobado (asumiendo el corte en 50).

La amplitud de este intervalo (unos 11 puntos) es consistente con la amplitud observada en los alumnos 0, 1 y 2. Esto indica que el modelo mantiene una precisión constante (homocedasticidad) y no se vuelve más impreciso al tratar con este perfil específico no perteneciente al modelo.

Para comprender globalmente el comportamiento del modelo, representamos gráficamente las bandas de confianza y predicción en función de la variable más determinante: las horas de estudio (`hours_studied`).

En este gráfico se aprecian visualmente las diferencias teóricas analizadas anteriormente:

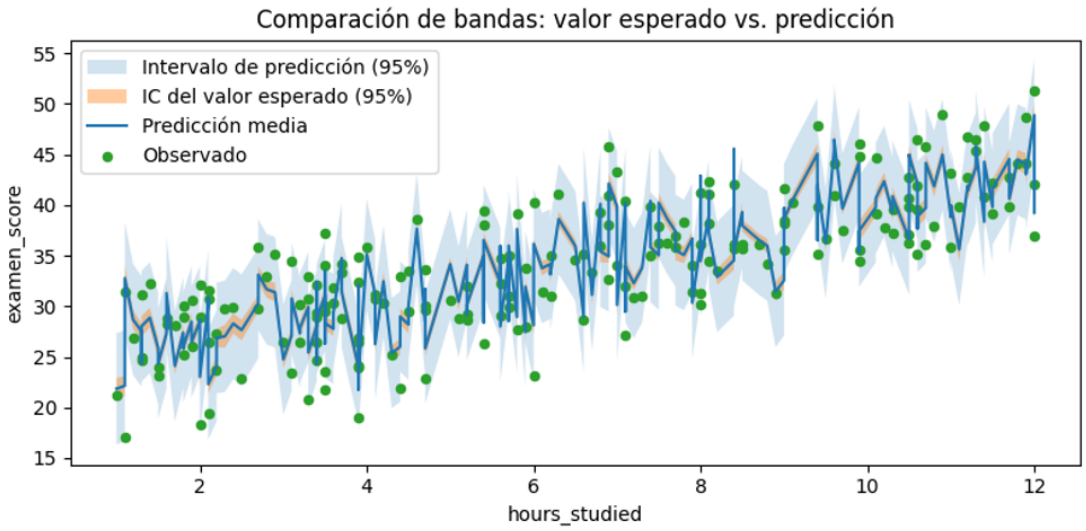

Figura 14: Comparación de bandas: valor esperado vs. predicción

- **La banda naranja (IC del valor esperado):** Es muy estrecha y sigue de cerca la línea de predicción media. Esto confirma visualmente que tenemos una gran certeza sobre dónde se sitúa el **rendimiento promedio** de los alumnos. El modelo tiene muy poco error de estimación de la media.
- **La banda azul claro (Intervalo de predicción):** Es notablemente más ancha y envuelve a la banda naranja. Su amplitud representa la variabilidad individual de los estudiantes. Como se observa, la gran mayoría de los puntos verdes (datos reales observados) caen dentro de esta zona azul, lo que valida que nuestros intervalos de predicción están bien calibrados para capturar el comportamiento real de los alumnos, incluyendo sus desviaciones aleatorias.
- **Tendencia:** La pendiente positiva es evidente; a medida que aumentan las horas de estudio (eje X), tanto la nota esperada como las bandas de probabilidad ascienden, ratificando la correlación positiva entre esfuerzo y resultado.

6. Conclusiones

6.1. Valoración general del ajuste realizado

El modelo diseñado para explicar las notas de los exámenes (`exam_score`) presenta un resultado muy satisfactorio. La principal fortaleza es su **alta capacidad de explicación**: el R-cuadrado de 0.841 nos indica que el 84 % de la variación en las notas se debe a las variables que hemos incluido (estudio, sueño, asistencia y notas previas).

Además, el modelo es **globalmente válido** (p-valor de la F casi cero), lo que significa que las variables elegidas no han sido seleccionadas al azar, sino que realmente ayudan a predecir la nota final.

Sin embargo, existen pequeños inconvenientes técnicos que debemos señalar para ser rigurosos:

- **La constante no es significativa:** El valor base de la nota cuando todo es cero no es estadísticamente fiable. Esto no afecta a las predicciones principales, pero sugiere que el modelo es menos preciso en casos extremos donde el alumno no hace nada.
- **Margen de error individual:** Aunque el modelo acierta muy bien con la ”nota media”de un grupo, tiene dificultades para predecir la nota exacta de un alumno concreto. Existe un margen de unos 11 puntos de diferencia que el modelo reconoce como ruido o factores personales que no podemos controlar.

6.2. Comentarios sobre el cumplimiento de los supuestos

El modelo presentado cumple con hipótesis clásicas de Gauss-Markov, lo que garantiza que nuestros estimadores OLS sean los mejores estimadores lineales insesgados:

- **Ausencia de Multicolinealidad:** El uso del Factor de Inflación de la Varianza (VIF) permitió descartar relaciones lineales graves entre las variables explicativas, con valores para las variables de interés situados en un rango óptimo de 1.004 a 1.050. Aunque el Número de Condición es elevado (882) y el VIF de la constante es alto (74.84), se determinó que se trata de colinealidad no esencial que no afecta a la precisión de los coeficientes de las variables de estudio.

- **Homocedasticidad (Varianza Constante):** La estabilidad de la varianza fue validada mediante métodos gráficos y analíticos. Los tests de Goldfeld-Quandt ($p = 0{,}4818$), Breusch-Pagan ($p = 0{,}9236$) y White ($p = 0{,}2055$) presentaron p-valores significativamente superiores al nivel de significancia de 0.05, lo que impide rechazar la hipótesis de homocedasticidad. Los diagramas de dispersión de los residuos frente a los valores predichos y frente a la variable principal (`exam_score`) muestran una nube de puntos aleatoria sin patrones definidos. La dispersión vertical se mantiene constante en todo el rango de valores, lo que visualmente ratifica la ausencia de heterocedasticidad. Para una mayor robustez, se aplicó el test de Glejser, analizando si la varianza de los residuos estaba relacionada funcionalmente con las variables `hours_studied` y `sleep_hours` bajo distintas potencias. Dado que todos los p-valores resultantes superaron el nivel de significancia, se concluye definitivamente que la varianza del error no depende de la magnitud de las variables independientes. Esto asegura que los errores estándar y los contrastes de significación son fiables.

- **Normalidad de los Errores:** Este supuesto es fundamental para garantizar la validez de los contrastes de significación individual (t) y global (F), así como para la precisión de los intervalos de confianza. El análisis se abordó desde tres perspectivas:

  - **Análisis Visual (Histograma):** El histograma de los residuos muestra una distribución que, aunque no presenta una forma de campana de Gauss perfecta, exhibe una simetría general centrada en cero. Se observa una frecuencia relativamente uniforme en los valores centrales, lo que motivó un análisis más riguroso.

  - **Gráfico Q-Q (Quantile-Quantile):** En este gráfico se observa una fuerte alineación de los residuos con la línea teórica de normalidad en la zona central. Aunque existen ligeras desviaciones en las çolas"(especialmente en la cola izquierda, donde aparecen observaciones más negativas de lo esperado), la tendencia general apoya la aproximación a la normalidad.

  - **Contraste Analítico:** A pesar de que las pruebas iniciales de Omnibus y Jarque-Bera sugerían dudas, el test de Kolmogorov-Smirnov (específico para la bondad de ajuste en muestras de este tamaño) arrojó un estadístico D de 0.0685 con un p-valor de 0.29117. Al ser este valor muy superior al nivel de significancia $\alpha = 0{,}05$, no existe evidencia estadística para rechazar la hipótesis nula. Aunque los gráficos no parezcan "perfectos.ª simple vista, el test estadístico confirma que el modelo es válido.

- **No autocorrelación:** Gráficamente, según el gráfico de evolución de los residuos, observamos que estos oscilan de manera aleatoria alrededor de la línea cero sin presentar ciclos, tendencias o patrones sistemáticos. Esto sugiere de forma preliminar que el error cometido en una observación no condiciona a las siguientes. Del mismo modo, el gráfico de dispersión con retardos, que enfrenta el residuo del momento t con su valor previo $t - 1$, muestra una nube de puntos dispersa sin una pendiente clara (ni ascendente ni descendente), lo que permite descartar visualmente la existencia de autocorrelación positiva o negativa. A estas verificaciones visuales sumamos la certeza que nos aportan los siguientes métodos analíticos: el contraste de Durbin-Watson, que arroja un valor de 2.034, situándose muy cerca del valor ideal de 2 y confirmando la ausencia de correlación serial de primer orden; el test de Ljung-Box, cuyos p-valores resultaron ser muy superiores al nivel de significancia de 0.05 en todos los retardos analizados, reforzando la hipótesis de independencia; y finalmente el método de Prais-Winsten, el cual estimó un parámetro de autocorrelación de -0.0366. Al ser este valor prácticamente nulo y comprobar que los resultados tras 9 iteraciones apenas difieren de la estimación original, se ratifica que el modelo no requería

correcciones adicionales.

6.3. Utilidad predictiva del modelo y posibles mejoras

La utilidad predictiva de este modelo es muy alta, especialmente cuando el objetivo es la estimación de comportamientos agregados. El modelo demuestra una precisión excepcional para determinar el valor esperado o promedio de la variable nota; esto se refleja en una banda de confianza notablemente estrecha (apenas 1.6 puntos de amplitud en los casos analizados). Esta característica otorga una gran certidumbre estadística a las instituciones educativas para identificar qué "perfil"de estudiante (según sus horas de estudio y asistencia) tendrá, en promedio, un rendimiento satisfactorio.

Su mayor utilidad reside en confirmar que las horas de estudio son el motor principal del rendimiento académico, con un impacto mucho mayor que el historial previo o el descanso. Por cada hora adicional de estudio, la nota aumenta en promedio 1,55 puntos.

No obstante, la predicción a nivel individual presenta mayores desafíos. Los intervalos de predicción son significativamente más amplios, manteniendo una amplitud constante de aproximadamente 11 puntos. Esta diferencia captura el ruidoïnherente a la realidad de cada estudiante (factores aleatorios como el estado anímico el día del examen o problemas de salud puntuales) que el modelo matemático no puede controlar.

A pesar del buen ajuste global ($R^2 = 0{,}841$), el análisis ha revelado puntos débiles que podrían fortalecerse en futuras investigaciones:

- **Inclusión de variables cualitativas y factores latentes:** El 16 % de la varianza no capturada sugiere que existen dimensiones críticas fuera del modelo. Factores como el nivel socioeconómico, el interés vocacional por la materia o la calidad de los hábitos de estudio (no solo la cantidad) podrían reducir el error residual y ofrecer una visión más completa del éxito académico.
- **Corrección de anomalías en la normalidad:** Para mitigar las contradicciones observadas inicialmente en los tests de Jarque-Bera y Omnibus, así como las desviaciones en las colas del gráfico Q-Q se podrían filtrar las observaciones con residuos muy elevados (los puntos que se alejan de la línea roja en el gráfico Q-Q) lo que ayudaría a que la distribución de errores fuera más puramente normal.
- **Normalización o Centrado de Variables para mitigar la no significancia de la constante:** Una de las razones por las que la constante no es significativa y presenta un VIF elevado (74.84) es que las variables explicativas tienen escalas muy distintas y no están centradas en el origen. Una mejora técnica consistiría en centrar las variables respecto a su media. Esto desplazaría el intercepto a un punto con mayor densidad de datos, lo que habitualmente reduce el error estándar de la constante, mejora su significatividad y elimina la colinealidad no esencial detectada en el Número de Condición.